

# 민감정보 파일 반출 탐지를 위한 AI 기반 Host DLP 시스템 설계 및 구현



팀명: Sentry

202155550/박동화/hvva1816@gmail.com

202121161/김진우/ a01047463862@gmail.com

202155579/이상호/ttt1253@naver.com

지도교수: 최윤희

제출일: 2026년 5월 15일

부산대학교

# 목차

|          |                                           |          |
|----------|-------------------------------------------|----------|
| <b>1</b> | <b>서론</b>                                 | <b>1</b> |
| 1.1      | 배경 및 필요성 . . . . .                        | 1        |
| 1.2      | 프로젝트 목표 . . . . .                         | 1        |
| 1.3      | 서비스 적용 시나리오 . . . . .                     | 2        |
| 1.4      | 기대 효과 . . . . .                           | 3        |
| <b>2</b> | <b>대상 조건 및 요구사항</b>                       | <b>4</b> |
| 2.1      | 대상 조건 . . . . .                           | 4        |
| 2.2      | 기능적 요구사항 . . . . .                        | 5        |
| 2.2.1    | 파일 반출 탐지 모듈 기능 . . . . .                  | 5        |
| 2.2.2    | AI 기반 민감 정보 판별 모듈 기능 . . . . .            | 6        |
| 2.2.3    | 결과 분석 웹 대시보드 기능 . . . . .                 | 6        |
| 2.3      | 비기능적 요구사항 . . . . .                       | 7        |
| 2.3.1    | 에이전트(Agent) 성능 및 호환성 . . . . .            | 7        |
| 2.3.2    | AI 모델 성능 및 처리 속도 . . . . .                | 7        |
| 2.3.3    | 대시보드 응답성 및 보안 . . . . .                   | 7        |
| 2.4      | 개발 환경 및 기술 스택 . . . . .                   | 8        |
| <b>3</b> | <b>시스템 설계</b>                             | <b>9</b> |
| 3.1      | 시스템 아키텍처 및 차별성 . . . . .                  | 9        |
| 3.1.1    | 2단계 하이브리드 탐지 구조의 차별성 . . . . .            | 9        |
| 3.1.2    | 전체 시스템 아키텍처 . . . . .                     | 10       |
| 3.1.3    | 데이터 흐름도 . . . . .                         | 12       |
| 3.2      | 세부 모듈 설계 . . . . .                        | 13       |
| 3.2.1    | 파일 반출 탐지 시나리오 및 설계 (Host Agent) . . . . . | 13       |
| 3.2.2    | 머신러닝 기반 민감 정보 판별 설계 . . . . .             | 13       |
| 3.2.3    | 결과 가시성 및 대시보드 구조 설계 . . . . .             | 14       |

|          |                           |           |
|----------|---------------------------|-----------|
| <b>4</b> | <b>평가 및 검증 방안</b>         | <b>15</b> |
| 4.1      | AI 모델 성능 평가 . . . . .     | 15        |
| 4.2      | 시스템 성능 및 안정성 평가 . . . . . | 15        |
| <b>5</b> | <b>프로젝트 관리</b>            | <b>17</b> |
| 5.1      | 추진 일정 . . . . .           | 17        |
| 5.2      | 역할 분담 . . . . .           | 17        |

# 제1장 서론

## 1.1 배경 및 필요성

현대의 기업 및 기관 환경에서는 클라우드 서비스, 웹메일, 사내 메신저 등 다양한 통신 채널의 발달로 인해 내부자의 악의적인 의도나 실수로 인한 민감정보 유출 위험이 지속적으로 증가하고 있다. 기존의 데이터 유출 방지(DLP, Data Loss Prevention) 솔루션은 주로 정규 표현식이나 키워드 매칭과 같은 룰(Rule) 기반의 탐지 방식을 사용해 왔다. 그러나 이러한 룰 기반 시스템은 데이터가 변형되거나 이미지 형태(PDF 등)로 변환될 경우 이를 인식하지 못하는 한계가 있으며, 오탐(False Positive) 및 미탐(False Negative) 비율이 높아 보안 관리자의 업무 부담을 가중시킨다.

더욱이 웹 브라우저나 메신저를 통한 데이터 전송은 대부분 HTTPS(TLS)로 강하게 암호화되어 있어 네트워크 패킷 모니터링 방식으로는 전송되는 파일의 내용을 검사할 수 없으며, 시스템 로그(Sysmon 등) 기반의 탐지는 데이터가 이미 유출된 이후에 기록을 남기는 '사후 탐지'에 머물러 원천적인 '사전 차단'이 불가능하다는 구조적 취약점이 존재한다. 따라서 우회 통신망 및 암호화 채널의 한계를 극복하기 위해 엔드포인트(Host) 운영체제(OS)의 가장 깊은 수준에서 파일 입출력을 통제하고, 머신러닝 기반의 자연어 처리(NLP)를 도입하여 문서의 문맥을 이해하고 변형된 민감정보까지 정확하게 식별할 수 있는 차세대 Host DLP 시스템의 도입이 필수적이다.

## 1.2 프로젝트 목표

본 프로젝트의 최종 목표는 엔드포인트(Host)에서 발생할 수 있는 다양한 파일 반출 시도를 원천적으로 탐지 및 차단하고, 인공지능(AI) 모델을 활용하여 파일 내부의 민감정보 여부를 정확히 판별하는 'AI 기반 Host DLP 시스템'을 설계하고 구현하는 것이다. 본 시스템은 다음과 같이 크게 세 가지 핵심 모듈로 구성된다.

첫째, **파일 반출 탐지 및 에이전트(Agent) 모듈**이다. 커널 미니필터(Kernel Minifilter) 및 사용자 모드 API 후킹(API Hooking) 기술을 적용하여 USB 이동식 매체로의 복사, 클

립보드 데이터 전송, 웹메일 및 메신저를 통한 파일 첨부 행위를 실시간으로 가로채어 사전 차단 체계를 구축한다.

둘째, **머신러닝 기반 민감정보 판별 AI 모듈**이다. 에이전트가 가로챈 파일 및 텍스트 데이터를 전달받아 문서 내부의 컨텍스트(Context)를 분석하고, 고도화된 AI 모델을 통해 개인정보 및 기밀 데이터 포함 여부를 높은 정확도로 판별한다.

셋째, **결과 분석 웹 대시보드(Web Dashboard)**이다. 탐지된 유출 시도 로그 및 통계 데이터를 시각화하여 보안 관리자에게 직관적인 모니터링 화면을 제공하고, 실시간 알림 기능을 통해 즉각적인 침해 사고 대응을 지원한다.

### 1.3 서비스 적용 시나리오

본 시스템이 실제 업무 환경에 도입되었을 때의 동작 과정을 직관적으로 이해하기 위해, 가장 빈번하게 발생하는 세 가지 대표적인 반출 시나리오를 정의한다.

#### ● 시나리오 1: 웹메일을 통한 기밀 문서 유출 시도 차단

1. 직원이 사내 기밀(영업 전략 등)이 포함된 PDF 파일을 개인 Gmail이나 사내 메신저에 첨부하여 외부 전송을 시도한다.
2. Host Agent가 브라우저의 파일 접근 행위를 즉각 가로채어 전송을 일시 정지(Hold)시키고 텍스트를 추출한다.
3. AI 분석 서버가 문맥을 분석하여 해당 문서가 '기밀(민감도 95%)'이라고 판별한다.
4. 첨부 동작이 강제로 실패(Fail) 처리되어 사용자에게 보안 경고가 노출되며, 보안 관리자 대시보드에 유출 시도 로그와 즉각적인 경고 알림이 발생한다.

#### ● 시나리오 2: 변형된 민감정보의 클립보드 복사 통제

1. 사용자가 단순 키워드 매칭을 피하기 위해 주민등록번호나 설계 코드의 일부를 교묘하게 변형하여 복사(Ctrl+C)한다.
2. 클립보드에 데이터가 담기는 즉시 Host Agent가 이를 AI 서버로 전송한다.
3. AI 모델이 문맥상 해당 데이터가 보호해야 할 민감정보임을 추론하여 차단 명령을 내린다.
4. 클립보드 내용이 "보안 정책에 의해 복사가 차단되었습니다"라는 경고 문구로 강제 변경되어, 붙여넣기(Ctrl+V)를 통한 외부 유출이 원천 차단된다.

#### ● 시나리오 3: USB 등 이동식 매체로의 파일 복사 통제

1. 내부자가 로컬 PC에 저장된 기밀 엑셀 파일이나 설계 도면을 개인 USB 드라이브로 복사하려 시도한다.
2. 커널 미니필터 기반의 Host Agent가 디스크 I/O 요청을 감지하고, 해당 파일이 외부 매체로 복사되기 직전에 작업을 대기(Hold)시킨다.
3. 에이전트가 파일의 텍스트 데이터를 추출하여 AI 모델에 판별을 요청하고, AI가 이를 민감정보로 식별한다.
4. OS 수준에서 파일 복사 I/O 요청이 강제 취소(Deny)되어 USB로의 복사가 원천적으로 차단되며, 관리자 대시보드에 유출 시도 내역이 기록된다.

## 1.4 기대 효과

본 프로젝트를 통해 개발되는 AI 기반 Host DLP 시스템이 완성될 경우, 다음과 같은 기술적, 보안적 기대 효과를 얻을 수 있다.

- **사전 차단 체계 확립 및 유출 가시성 확보:** 기존 시스템 로그 모니터링 방식이 가지던 탐지 지연(Race Condition) 문제를 해결하고, OS 레벨의 API 및 I/O 제어를 통해 민감정보가 외부로 빠져나가기 직전에 원천적으로 차단할 수 있다. 또한, HTTPS 암호화 이전에 파일 접근을 통제하여 네트워크 가시성 부재 문제를 극복할 수 있다.
- **AI 기반 탐지로 보안 정확도 향상:** 룰 기반 탐지를 회피하기 위해 교묘하게 변형된 텍스트나 문서 데이터라도 AI 알고리즘이 문맥을 추론하여 식별함으로써 미탐을 최소화하고, 정상적인 업무 데이터에 대한 과도한 차단(오탐)을 줄여 업무 효율성을 보장할 수 있다.
- **통합적인 엔드포인트 보안 관리:** 클립보드 제어부터 USB 매체 통제, 네트워크 전송 차단까지 통상적인 모든 반출 시나리오를 단일 에이전트(Agent) 내에서 통합 관리함으로써 엔드포인트 보안 수준을 획기적으로 높일 수 있다.

## 제2장 대상 조건 및 요구사항

### 2.1 대상 조건

본 프로젝트에서 설계 및 구현하는 'AI 기반 Host DLP 시스템'이 원활하게 동작하고 목표 성능을 평가받을 수 있도록, 시스템이 적용되는 타겟 환경 및 제약 사항을 다음과 같이 정의한다.

- 운영 체제 및 동작 환경:

- **Host Agent:** 커널 미니필터 및 Win32 API 후킹 기술을 직접적으로 제어해야 하므로, 에이전트가 설치되는 엔드포인트 운영체제는 Windows 10 및 Windows 11(64-bit) 환경으로 한정하여 개발을 진행한다.
- **AI 분석 서버:** 딥러닝 기반 자연어 처리(KoELECTRA) 모델의 실시간 추론을 요구하므로, 원활한 응답 속도 확보를 위해 GPU 연산 가속이 지원되는 백엔드 서버 환경을 전제로 한다.
- **Web Dashboard:** 크롬(Chrome), 엣지(Edge) 등 최신 모던 웹 브라우저 환경에서 접속하는 보안 관리자 PC를 대상으로 한다.

- 통제 대상 반출 경로: 기존 시스템의 한계를 극복하기 위해 본 시스템은 다음 3가지 핵심 유출 경로를 모니터링 대상으로 한정한다.

- 로컬 디스크에서 이동식 저장매체(USB 드라이브 등)로의 파일 복사 및 이동
- 웹 브라우저(웹메일, 클라우드 스토리지) 및 PC용 사내 메신저를 통한 파일 첨부 전송
- 텍스트 데이터의 클립보드 복사(Ctrl+C) 이벤트

- 검사 대상 파일 및 데이터:

- 파일 반출 시, AI 모델이 문맥을 분석할 수 있도록 텍스트 추출이 용이한 파일(TXT, PDF, 엑셀/워드 등 MS Office 문서)을 주 검사 대상으로 삼는다.

- 텍스트화가 불가능한 이미지(JPG, PNG) 기반의 도면이나 스캔본 등에 대한 광학 문자 인식(OCR) 기능은 본 시스템의 1차 구축 범위에서 제외한다.

## 2.2 기능적 요구사항

### 2.2.1 파일 반출 탐지 모듈 기능

본 모듈은 Host PC 내에서 발생할 수 있는 다양한 형태의 데이터 반출 시도를 원천적으로 탐지하고 차단하는 역할을 수행한다. 특히 기존 이벤트 로그 모니터링 방식의 한계인 '탐지 지연(Race Condition)' 및 '네트워크 암호화(HTTPS)로 인한 내용 검사 불가' 문제를 극복하기 위해, OS 커널 수준의 제어와 사용자 모드(User-Mode) API 후킹 기술을 복합적으로 적용한다. 주요 기능은 다음과 같이 세 가지 반출 시나리오에 대한 사전 통제로 구성된다.

- **USB 및 로컬 매체 파일 이동 통제 (커널 미니필터 기반)**

이동식 저장장치(USB 등)로 파일 복사 및 이동 행위를 실시간으로 탐지한다. Microsoft의 Windows-driver-samples(Scanner 예제)를 활용하여 커널 미니필터(Kernel Minifilter) 드라이버를 구현한다. 파일 I/O 요청 발생 시 OS 단에서 해당 작업을 일시 정지(Hold)시키고, 파일 내용을 추출하여 AI 분석 모듈로 전달한다. AI 모델의 민감정보 포함 여부 판별 결과에 따라 I/O 요청을 최종 승인하거나 강제 취소(차단)함으로써 원천적인 반출 방지를 수행한다.

- **웹메일 및 사내 메신저 첨부 통제 (API 후킹 기반)**

웹 브라우저(Chrome, Edge 등)나 메신저를 통한 파일의 외부 네트워크 전송을 탐지한다. HTTPS/TLS 패킷 암호화로 인해 네트워크 단에서 파일 내용을 검사할 수 없는 원천적 한계를 극복하기 위해, Microsoft Detours 또는 EasyHook 라이브러리를 활용한 API 후킹을 적용한다. 대상 프로세스에 DLL을 주입하여 파일을 읽어 들이는 핵심 API(CreateFile, ReadFile 등) 호출을 가로챈다. 검사 결과 민감정보가 검출될 경우 해당 API 호출 자체를 실패(Fail) 처리하여 메일이나 메신저의 파일 첨부 기능을 무력화한다.

- **클립보드 데이터 복사 통제 (Win32 API 전역 후킹)**

단순 텍스트 형태의 민감정보가 클립보드를 통해 복사 및 외부로 유출되는 것을 방지한다. 주기적으로 로그를 확인하는 폴링(Polling) 방식 대신, Win32 API의 SetWindowsHookEx를 활용한 전역 후킹(Global Hook)을 설정한다. 이를 통해 WM\_CLIPBOARDUPDATE 이벤트를 즉시 감지할 수 있다. 사용자가 복사(Ctrl+C)를 수행함과 동시에 클립보드 데이터를 AI 모듈로 검사하며, 민감정보로 판단될 경우 클립보드 데이터를

보안 경고 문구로 덮어쓰거나 강제 삭제한다. 결과적으로 붙여넣기(Ctrl+V)를 통한 유출을 원천 차단한다.

### 2.2.2 AI 기반 민감 정보 판별 모듈 기능

본 모듈은 호스트 에이전트로부터 전달받은 반출 데이터를 분석하여 기밀성 여부를 최종 확정하는 시스템의 '의사결정 엔진' 역할을 수행한다.

- **비정형 데이터 문맥 분석:** KoELECTRA 모델을 활용하여, 단순 키워드 매칭으로는 식별이 어려운 기술 설계도 설명문, 영업 전략 등 비정형 텍스트 내의 기밀 맥락을 파악한다.
- **기밀 확률 수치화:** 분석된 콘텐츠를 바탕으로 기밀 확률(0% ~ 100%)을 산출하며, 이를 통해 정책에 따른 유연한 차단 및 허용 제어가 가능하게 한다.

### 2.2.3 결과 분석 웹 대시보드 기능

결과 분석 웹 대시보드는 Host Agent에서 수집한 파일 반출 시도 로그와 AI 모델의 민감정보 판별 결과를 보안 관리자가 확인할 수 있도록 제공하는 중앙 관제 화면이다. 본 대시보드는 단순한 로그 저장소가 아니라, 유출 시도 현황을 시각적으로 분석하고 고위험 이벤트를 빠르게 파악할 수 있도록 설계한다. 주요 기능적 요구사항은 다음과 같다.

- **탐지 로그 수집:** Host Agent가 전송한 파일 반출 시도 로그를 웹 서버에서 수신하고 데이터베이스에 저장한다.
- **탐지 로그 조회:** 발생 시간, 사용자 ID, Host IP, 파일명, 반출 경로, 탐지 방식, AI 민감도 점수, 처리 결과를 표 형태로 조회할 수 있도록 한다.
- **통계 시각화:** 일별 탐지 건수, 차단 및 허용 비율, 반출 경로별 비율, AI 민감도 점수 분포 등을 차트로 제공한다.
- **상세 로그 확인:** 특정 로그를 선택하면 해당 이벤트의 상세 정보와 차단 사유, 매칭된 주요 키워드 등을 확인할 수 있도록 한다.
- **위험도 알림 표시:** AI 민감도 점수가 높은 이벤트나 차단된 이벤트는 대시보드에서 강조 표시하여 관리자가 우선적으로 확인할 수 있도록 한다.

## 2.3 비기능적 요구사항

### 2.3.1 에이전트(Agent) 성능 및 호환성

본 에이전트는 엔드포인트 단말기에서 백그라운드 프로세스로 상시 동작하므로, 사용자의 체감 성능 저하를 최소화하고 시스템 안정성을 보장해야 한다.

- **시스템 리소스 최적화:** 에이전트의 기본 동작 상태에서 CPU 점유율은 5% 미만, 메모리(RAM) 사용량은 100MB 이하를 유지하여 사용자 업무 환경에 미치는 영향을 최소화한다.
- **OS 호환성:** 커널 미니필터 및 Win32 API 후킹 기술을 활용하므로, 주 타겟 운영체제인 Windows 10 및 Windows 11 환경에서 정상적으로 동작해야 한다.
- **시스템 안정성 (Fail-Safe):** 커널 레벨에서 동작하는 미니필터 드라이버의 오류로 인한 시스템 크래시(블루스크린, BSOD)를 방지하기 위해 예외 처리를 철저히 설계한다. 또한, AI 분석 모듈과 통신이 불가능한 장애 상황에서는 정책에 따라 기본 허용(Allow) 또는 기본 차단(Block)으로 동작하도록 장애 대응(Fail-Safe) 로직을 구현한다.

### 2.3.2 AI 모델 성능 및 처리 속도

전수 검사 방식의 안정적인 운영을 위해 다음과 같은 성능 목표를 설정한다.

- **추론 지연 시간(Latency) 최소화:** 사용자 업무에 지장을 주지 않도록 텍스트 수신부터 판별 결과 반환까지의 시간을 모델 경량화를 통해 최대한 줄인다.
- **분류 정확도(F1-Score):** 기밀 데이터 누락(False Negative)을 방지하기 위해 90% 이상의 재현율(Recall) 확보를 목표로 모델을 최적화한다.

### 2.3.3 대시보드 응답성 및 보안

웹 대시보드는 보안 관리자가 탐지 현황을 빠르게 확인할 수 있어야 하므로 로그 조회와 통계 화면의 응답성을 확보해야 한다. 또한 탐지 로그에는 사용자 정보, 파일명, 반출 경로, 민감도 점수 등 보안상 중요한 정보가 포함되므로 관리자 인증과 접근 제어가 필요하다.

- **화면 응답성:** 로그 목록, 통계 차트, 상세 조회 화면은 사용자가 지연 없이 확인할 수 있도록 구성한다.
- **관리자 인증:** 대시보드는 허가된 관리자만 접근할 수 있도록 로그인 기능을 제공한다.

- **접근 제어:** 일반 사용자와 관리자를 구분하여 민감한 로그 데이터에 대한 접근을 제한한다.
- **로그 무결성:** 탐지 로그는 사고 분석 자료로 활용될 수 있으므로 임의 수정 및 삭제를 제한한다.
- **통신 보안:** 실제 운영 환경에서는 HTTPS 기반 통신을 적용하여 Host Agent와 웹 서버 간 로그 전송 과정의 보안을 강화한다.

## 2.4 개발 환경 및 기술 스택

본 프로젝트는 에이전트, AI 모델, 웹 대시보드의 세 가지 파트로 구성되며, 각 모듈의 특성에 최적화된 언어 및 프레임워크를 선정하여 개발을 진행한다.

- **Host Agent (탐지 및 제어):**
  - 언어: C/C++, Python
  - 핵심 기술: Windows Driver Kit (WDK) 미니필터 샘플(Scanner), Microsoft Detours (API 후킹), ctypes / pywin32 (Python API 연동)
- **AI 모델 (분석 및 판별):**
  - 언어: Python
  - 프레임워크: PyTorch / Hugging Face
  - 모델: KoELECTRA
- **Web Dashboard (가시성 및 관리):**
  - Frontend: HTML, CSS, JavaScript, Bootstrap 5, Chart.js
  - Backend: Python, FastAPI, Uvicorn
  - Database: PostgreSQL
- **협업 및 버전 관리:** Git, GitHub, Notion

## 제3장 시스템 설계

### 3.1 시스템 아키텍처 및 차별성

#### 3.1.1 2단계 하이브리드 탐지 구조의 차별성

본 시스템은 기존 DLP 솔루션의 한계를 극복하기 위해 '2단계 하이브리드 탐지(2-Tier Hybrid Detection)' 메커니즘을 채택한다. 이는 실시간성(Real-time)과 정확성(Accuracy)의 균형을 극대화한 구조이다.

- **전수 조사 부하 해소:** 엔드포인트 환경에서 모든 파일에 대해 딥러닝 추론을 수행하는 것은 심각한 리소스 점유를 야기한다. 따라서 가벼운 Rule 기반 필터링을 선행하여 불필요한 연산을 줄인다.
- **문맥 기반의 기밀 식별:** '비밀'이라는 단어가 포함되지 않았더라도, 문장의 흐름상 내부 기획안이나 독자 기술을 설명하는 비정형 텍스트는 기존 시스템이 놓치는 치명적인 사각지대이다. KoELECTRA 모델은 이러한 '의미적 기밀성'을 포착하여 보안 사고를 원천 차단한다.
- **지능형 임계값 설정:** 단순 차단/허용의 이분법적 사고를 넘어, AI가 산출한 기밀 확률(0 ~ 100%)을 바탕으로 기업의 보안 정책에 따라 유연한 대응이 가능하다.

기존 방식과 본 제안 시스템의 차별점은 표 3.1과 같다.

| 구분     | 기존 DLP (Rule-based)  | 본 제안 시스템 (Hybrid AI)    |
|--------|----------------------|-------------------------|
| 탐지 방식  | 정규표현식 및 키워드 단순 매칭    | 1차 패턴 매칭 + 2차 AI 문맥 분석  |
| 탐지 대상  | 주민번호, 계좌번호 등 정형 패턴   | 기술 문서, 영업 비밀 등 비정형 문맥   |
| 회피 대응  | 단어 변형(비.밀 등) 시 탐지 불가 | 의미론적 분석으로 변형 표현 식별 가능   |
| 리소스 효율 | 모든 파일 전수 검사 시 부하 발생  | 룰 필터링 후 의심 데이터만 AI 추론   |
| 판단 기준  | 단순 키워드 포함 여부         | 문서 내 단어 상관관계 및 기밀 확률(%) |

표 3.1: 기존 솔루션과 본 제안 시스템의 비교

### 3.1.2 전체 시스템 아키텍처

본 시스템은 엔드포인트 단말에서 파일 반출을 실시간으로 통제하는 '사용자 PC(Host Agent)', 수집된 데이터를 바탕으로 문맥을 추론하는 'AI 분석 서버', 그리고 관리자에게 통합 관제 환경을 제공하는 '보안 대시보드'의 3계층(3-Tier) 아키텍처로 구성된다. 시스템의 전체적인 구성 요소와 데이터 흐름은 그림 3.1와 같다.




그림 3.1: AI 기반 Host DLP 시스템 아키텍처

그림 3.1에 나타난 바와 같이, 각 계층의 핵심 역할은 다음과 같이 정의된다.

- **사용자 PC (Host Agent):** 엔드포인트 단말에서 동작하며, 파일 복사 및 메일 첨부 등의 반출 행위 '탐지', 운영체제 수준의 I/O '제어(차단/허용)', 그리고 검사를 위한 원본 '데이터 전송' 역할을 수행한다.
- **AI 분석 서버 (백엔드):** Host Agent로부터 수신한 텍스트 데이터를 기반으로 지능형 '문맥 분석'을 수행하고, 기밀 데이터 포함 확률을 수치화하여 최종 '민감도 산출'을 담당한다.
- **보안 대시보드 (관리자):** 분석 서버에서 산출된 데이터를 바탕으로 전체 탐지 현황 '시각화', 차단 및 예외 처리를 위한 '정책 관리', 그리고 고위험 유출 시도 발생 시 즉각적인 '알림' 기능을 제공한다.

시스템 계층 간의 상호작용 및 데이터 흐름은 크게 두 단계로 구분된다.

1. **사용자 PC ↔ AI 분석 서버 (양방향 통신):** 사용자의 파일 반출 시도가 탐지되면 Agent는 해당 프로세스를 대기(Hold)시키고 AI 서버로 '추론 요청'을 보낸다. 서버는 실시간으로 민감도를 판별한 뒤, 그 결과에 따른 '차단 또는 허용 명령'을 Agent로 반환하여 물리적인 통제가 이루어지게 한다.
2. **AI 분석 서버 → 보안 대시보드 (단방향 통신):** AI 서버에서 분석이 완료된 이벤트의 '로그 및 분석 데이터'는 대시보드로 전달된다. 이를 통해 보안 관리자는 어떤 PC에서 어떤 파일이 반출 차단되었는지 사후 감사 및 모니터링을 수행할 수 있다.

### 3.1.3 데이터 흐름도

본 시스템의 데이터 흐름은 그림 3.2와 같이 사용자 파일 반출 시도, Host Agent 탐지, AI 기반 민감정보 판별, 차단 또는 허용 제어, 로그 저장, 관리자 대시보드 표시의 순서로 이루어진다.




그림 3.2: AI 기반 Host DLP 시스템 데이터 흐름도

## 3.2 세부 모듈 설계

### 3.2.1 파일 반출 탐지 시나리오 및 설계 (Host Agent)

본 모듈은 기존 이벤트 로그 모니터링 방식의 한계인 '탐지 지연(Race Condition)' 및 '네트워크 암호화(HTTPS)로 인한 내용 검사 불가' 문제를 극복하기 위해, OS 커널 수준의 제어와 사용자 모드(User-Mode) API 후킹 기술을 복합적으로 적용하여 설계한다.

- **USB 및 로컬 매체 파일 이동 통제 (커널 미니필터 기반):** Microsoft의 Windows-driver-samples(Scanner 예제)를 활용하여 커널 미니필터(Kernel Minifilter) 드라이버를 구현한다. 파일 I/O 요청 발생 시 OS 단에서 해당 작업을 일시 정지(Hold)시키고 파일 내용을 AI 모듈로 전달하며, 반환된 결과에 따라 I/O 요청을 최종 승인하거나 강제 취소한다.
- **웹메일 및 사내 메신저 첨부 통제 (API 후킹 기반):** HTTPS 패킷 암호화의 한계를 극복하기 위해, Microsoft Detours 또는 EasyHook 라이브러리를 활용하여 웹 브라우저나 메신저 프로세스에 DLL 주입을 시도한다. 파일 읽기 API(CreateFile, ReadFile) 호출을 가로채어 사전 검사하고, 민감정보 검출 시 API 호출을 실패(Fail) 처리한다.
- **클립보드 데이터 복사 통제 (Win32 API 전역 후킹):** 주기적 폴링(Polling) 방식 대신 Win32 API의 SetWindowsHookEx를 활용한 전역 후킹(Global Hook)을 설정하여 WM\_CLIPBOARDUPDATE 이벤트를 즉시 감지하고 텍스트를 검사한다.

### 3.2.2 머신러닝 기반 민감 정보 판별 설계

본 모듈은 기존 방식의 한계인 비정형 데이터의 문맥 파악 불가 문제를 해결하기 위해, 에이전트로부터 전달받은 다차원 데이터를 심층 분석하는 지능형 엔진을 설계한다.

- **데이터 전처리:** 에이전트가 후킹을 통해 추출한 파일 본문(Raw Content)과 더불어 파일 메타데이터(확장자, 경로), 사용자 정보(부서, 권한)를 결합하여 분석 데이터셋을 구성한다.
- **KoELECTRA 및 DMLPNN 연계 구조:** 한국어 문맥 파악에 특화된 KoELECTRA를 통해 문서의 핵심 특징(Feature)을 추출하고, 이를 심층 다층 퍼셉트론(DMLPNN)의 입력값으로 사용하여 기밀 여부를 최종 분류한다. 이러한 파이프라인 구조는 단순 이진 분류를 넘어 데이터의 복합적인 유출 위험도를 정밀하게 산출할 수 있게 한다.

### 3.2.3 결과 가시성 및 대시보드 구조 설계

본 대시보드는 Host Agent에서 수집한 파일 반출 시도 로그와 AI 모델의 민감정보 판별 결과를 보안 관리자가 직관적으로 확인할 수 있도록 설계한다. 단순히 로그를 나열하는 것이 아니라, 전체 보안 현황을 요약하고 위험도가 높은 이벤트를 빠르게 파악할 수 있도록 시각화 중심의 구조를 적용한다. 대시보드는 크게 메인 대시보드, 탐지 로그 조회 화면, 상세 분석 화면으로 구성한다.

- **메인 대시보드:** 전체 탐지 건수, 차단 건수, 허용 건수, 고위험 이벤트 수를 카드 형태로 표시한다. 또한 일별 탐지 추이, 반출 경로별 비율, AI 민감도 점수 분포를 차트로 제공하여 관리자가 전체적인 유출 시도 현황을 한눈에 파악할 수 있도록 한다.
- **탐지 로그 조회 화면:** Host Agent로부터 수집된 이벤트 로그를 표 형태로 제공한다. 각 로그는 발생 시간, 사용자 ID, Host IP, 파일명, 반출 경로, 탐지 방식, AI 민감도 점수, 처리 결과를 포함한다. 관리자는 기간, 사용자, 반출 경로, 차단 여부 등을 기준으로 검색 및 필터링할 수 있다.
- **상세 분석 화면:** 특정 로그를 선택하면 해당 이벤트의 상세 정보를 확인할 수 있도록 한다. 상세 정보에는 파일명, 발생 PC, 반출 시도 경로, AI 민감도 점수, 매칭된 주요 키워드, 차단 사유, 최종 처리 결과가 포함된다. 이를 통해 관리자는 AI 모델이 왜 해당 파일을 민감정보로 판단했는지 확인할 수 있다.
- **알림 및 위험도 표시:** 고위험 반출 시도가 발생한 경우 대시보드 상단에 경고 알림을 표시하고, 로그 목록에서는 위험도에 따라 시각적으로 구분한다. 이를 통해 관리자가 중요한 보안 이벤트를 우선적으로 확인할 수 있도록 한다.

## 제4장 평가 및 검증 방안

### 4.1 AI 모델 성능 평가

설계된 모델의 실효성을 검증하기 위해 다음과 같은 평가를 수행한다.

- **탐지 정밀도 및 재현율:** 기밀 문서 판별의 정확성을 측정하기 위해 F1-Score 90% 이상 달성을 목표로 하며, 특히 기밀을 놓치지 않는 재현율 성능에 집중하여 평가한다.
- **종단 간 지연 시간:** 파일 반출 시도 시점부터 AI 판별 후 차단/허용 신호가 에이전트에 도달할 때까지의 총 시간을 측정하여 시스템 가용성을 해치지 않는 수준의 응답 속도 확보를 목표로 한다.

### 4.2 시스템 성능 및 안정성 평가

본 시스템은 엔드포인트 커널 및 사용자 모드에서 직접 동작하는 에이전트를 포함하므로, 사용자 PC의 가용성을 침해하지 않도록 다음과 같은 성능 및 안정성 평가를 수행한다.

- **에이전트 리소스 점유율 측정:** 에이전트가 백그라운드에서 대기할 때(Idle 상태)와 대용량 파일 복사 및 탐지 이벤트가 발생할 때(Active 상태)의 CPU 및 메모리(RAM) 사용량을 모니터링한다. CPU 점유율 5% 미만, 메모리 사용량 100MB 이하 유지를 성공 기준으로 삼아 업무 환경에 미치는 영향을 평가한다.
- **OS 안정성 및 충돌 검증:** 커널 미니필터 드라이버 및 API 후킹 모듈이 Windows 10 및 11(64-bit) 환경에서 시스템 크래시(블루스크린, BSOD)나 응용 프로그램 응답 없음 현상을 유발하지 않는지 확인하기 위해, 대량의 파일 입출력 스트레스 테스트를 진행하여 시스템 안정성을 검증한다.
- **장애 대응(Fail-Safe) 동작 테스트:** AI 분석 서버와의 네트워크 연결이 단절되거나 에이전트 프로세스가 강제 종료되는 등의 예기치 못한 장애 상황을 의도적으로 시뮬레이션한다. 이러한 상황에서 PC의 파일 시스템 전체가 멈추는(Lock) 현상 없이, 사전에 정의된 보안 정책(기본 차단 혹은 기본 허용)에 따라 우회 동작하는지 확인한다.

- **대시보드 및 서버 부하 테스트:** 다수의 Host PC에서 동시에 파일 반출 시도 로그가 전송되는 상황을 가정하여, 백엔드 서버와 데이터베이스가 지연 없이 로그를 수집하고 웹 대시보드에 실시간으로 반영할 수 있는지 동시 처리 성능을 평가한다.

## 제5장 프로젝트 관리

### 5.1 추진 일정

| 구분 | 주요 추진 내용                                | 5월 | 6월 | 7월 | 8월 | 9월 |
|----|-----------------------------------------|----|----|----|----|----|
| 공통 | 시스템 아키텍처 및 데이터 통신 규격 공동 설계              |    |    |    |    |    |
| AI | KoELECTRA 모델 Fine-tuning 및 데이터 파이프라인 구축 |    |    |    |    |    |
| 보안 | 커널 제어, API 후킹 기반 반출 탐지 Agent 개발         |    |    |    |    |    |
| 웹  | FastAPI 기반 로그 수집 서버 및 관리자 대시보드 개발       |    |    |    |    |    |
| 공통 | [협업] 통합 시스템 연동 및 파이프라인 구축               |    |    |    |    |    |
| 공통 | [협업] 탐지 성능 및 시스템 부하 테스트 / 디버깅           |    |    |    |    |    |
| 공통 | 프로젝트 최종 산출물 정리 및 발표 준비                  |    |    |    |    |    |

표 5.1: 프로젝트 세부 추진 및 협업 일정표

### 5.2 역할 분담

- 공통 (시스템 기획 및 연동)

- 2단계 하이브리드 탐지 구조(Rule + AI)에 대한 전체 시스템 아키텍처 공동 설계
- Host Agent ↔ AI 분석 서버 간의 실시간 데이터 통신 규격(JSON 형식, REST API) 정의 및 통합 테스트 진행

- 박동화

- KoELECTRA 기반 분류 모델 설계 및 Fine-tuning
- 데이터 전처리 파이프라인 및 증강 로직 구현

- 김진우

- 커널 미니필터 및 Win32 API 후킹 기반 파일 반출(USB, 메일/메신저, 클립보드) 사전 탐지 모듈 구현

- Host Agent와 AI 분석 서버 간의 실시간 데이터 송수신 및 프로세스 I/O 제어 (차단/허용) 로직 개발

- 이상호

- Host Agent로부터 탐지 로그를 수신하는 FastAPI 기반 웹 서버 및 REST API 구현
- 탐지 로그 조회, 통계 차트 시각화, 상세 로그 확인 기능을 포함한 관리자 웹 대시보드 구현