

민감정보 파일 반출 탐지를 위한 AI 기반 Host DLP 시스템 설계 및 구현



팀: Sentry

팀원:

박동화(202155550)

김진우(202121161)

이상호(202155579)

지도교수: 최윤희

목차

✓ 1. 연구 배경 및 목적

✓ 2. 시스템 개요

✓ 3. 프로그램 구현

✓ 4. 테스트 결과


✓ 5. 결론 및 향후 과제



01

연구 배경 및 목적

- 연구 배경
- 문제 정의
- 연구 목적



1.1 개발 배경

엔드포인트 정보 유출 위협의 확산

기업 내부정보는 메일뿐 아니라 클립보드, 웹메일, 클라우드 드라이브, USB 등 엔드포인트에서 직접 반출되는 경로가 늘어나고 있습니다. 네트워크 DLP만으로는 HTTPS·로컬 동작을 놓치기 쉽고, 정규식·키워드만으로는 문맥을 구분하지 못해 오탐·미탐이 발생하며, 한 번 유출된 데이터는 사후 회수가 어렵습니다.

본 프로젝트는 다채널 유출 시나리오를 바탕으로 Windows Host Agent로 실시간 탐지·차단을 수행하고, KoELECTRA 기반 AI 서버로 allow/review/block을 판정하며, Web Dashboard로 중앙 모니터링하는 AI 기반 Host DLP(Sentry)를 구현하는 것을 목표로 합니다.



1.2 문제 정의

본 연구는 다채널 유출, 탐지 정확도, 실시간 차단, 관리 가시성의 네 가지 문제를 해결 대상으로 정의합니다.

1	다채널 유출	클립보드, 웹메일, 클라우드 드라이브, USB 등 반출 경로가 분산됨
2	탐지 정확도	단순 패턴 매칭만으로는 기밀 문맥을 구분하기 어려움
3	실시간성	업로드·붙여넣기는 한 번 나가면 회수가 어려워 즉시 차단이 중요
4	가시성	차단 사건만으로는 부족, 관리자용 로그·대시보드가 필요

1.3 연구 목적

AI 기반 Host DLP 시스템(Sentry)

🎯 **프로젝트 목적:** 본 연구는 정규식과 AI 문맥 분석을 결합한 하이브리드 Host DLP를 제안하고, 다채널 실시간 차단과 중앙 모니터링의 실효성을 검증하는 것을 목적으로 합니다.

1. **Host Agent:** Windows PC에서 유출 채널을 실시간 탐지·차단
2. **AI Server:** 정규식 1차 필터 + KoELECTRA 문맥 분석으로 allow / review / block 판정
3. **Web Dashboard:** 탐지 로그 수집·시각화·고위험 알림으로 중앙 모니터링


✨ 기대 효과

- 오탐을 줄이면서도 민감정보 유출을 사전 차단
- 채널별 통합 대응 + 관리자 가시성 확보

02

시스템 개요

- 시스템 구성
- 전체 아키텍처
- 기술 스택



2.1 시스템 구성 (1)




2.1 시스템 구성 (2)



2.1 시스템 구성 (3)



2.2 전체 아키텍처



2.3 기술 스택

Host Agent

- **Python**: Windows
엔드포인트 탐지·차단 핵심 언어
- **pywin32**: 클립보드 훅 · Outlook COM · 서비스
- **mitmproxy**: 웹메일·클라우드 HTTPS MITM 검사
- **aiosmtpd**: 로컬 SMTP 프록시 차단
- **Git / GitHub**: 형상 관리 및 3개 레포 협업

AI Server

- **FastAPI · Uvicorn**: 추론 API 서버 (/api/v1/analyze)
- **KoELECTRA**: 한국어 문맥 기반 기밀 판별
- **PyTorch · Transformers**: 모델 학습·추론
- **scikit-learn**: threshold · ROC/PR 평가
- **Colab · Cloudflare Tunnel**: GPU 서빙 · 외부 연동


Web Dashboard

- **FastAPI · SQLite**: 로그 API · 로컬 DB 저장
- **HTML · Chart.js**: KPI 대시보드 · 로그 시각화
- **Pydantic**: 요청/응답 스키마 검증
- **pytest · httpx**: API·연동 테스트
- **X-Agent-Token**: 에이전트 로그 수집 인증


03

프로그램 구현

- 전체 동작 파이프라인
- Host Agent
- AI Server
- Web Dashboard



3.1 전체 동작 파이프라인




3.2 Host Agent

Host Agent는 클립보드, 웹메일·클라우드 드라이브, USB 채널에서 반출을 감지하며, 채널별로 붙여넣기 억제, HTTP 451, 파일 삭제로 차단합니다.





3.3 AI Server

AI 서버는 KoELECTRA(v7) 문맥 분석 결과를 confidence_score로 산출하고, 두 개의 threshold(0.20, 0.41)로 block/review/allow 3단계 판정을 내립니다.



FastAPI 응답 (event_id · decision · confidence_score) → Host Agent / Web Dashboard


3.4 Web Dashboard



04

테스트 결과

- 테스트 방식
- 테스트 결과
- 결과 분석



4.1 테스트 방식

4개 채널 × 34개 파일 형식 × 5개 크기 구간, 총 680케이스를 측정했습니다.

1	대상 채널	클립보드 · 웹메일 · 클라우드 드라이브 · USB
2	파일 크기	10 KB / 100 KB / 1 MB / 10 MB / 50 MB
3	측정 구간	extract → regex → send → ai → recv → block
4	환경	Host: Win11 / i5-13400F / 32GB · AI: i5-14400F / 32GB (CPU)

4.2 테스트 결과 (1) - 100KB 채널 별 결과

단위(ms)

채널	extract	regex	send	ai	recv	block	total
클립보드	7.54	7.27	226.90	273.20	226.90	40.20	782.01
웹메일	9.39	7.29	226.89	245.98	226.89	1.41	717.85
클라우드 드라이브	11.06	8.25	243.47	292.98	243.47	1.67	800.90
USB	2,008.90	8.45	296.00	242.67	296.00	71.30	2,923.32

4.2 테스트 결과 (2) - 전체 채널 평균

단위(ms)

파일 크기	extract	regex	send	ai	recv	block	total
10 KB	507.66	1.24	244.02	264.52	244.02	27.63	1,289.10
1 MB	580.93	76.87	250.68	266.97	250.68	28.33	1,454.45
10 MB	1,300.62	743.15	258.72	270.24	258.72	28.25	2,859.70
50 MB	2,377.13	3,692.24	269.37	273.35	269.37	28.44	6,909.88

4.3 테스트 결과

100 KB~1 MB 구간에서 USB 제외 1초 이내 탐지·차단, AI는 240~295 ms로 안정

 클립보드

● 즉시 억제 후 AI는 백그라운드

 웹메일/드라이브

● 정상 파일은 지연 없음 / 차단은 HTTP 451

 USB

● 사후 검사 ~3초, 복사 직후 삭제

실사용 구간(100 KB~1 MB)에서 클립보드·웹 채널은 1초 이내로 탐지·차단되고, AI 추론은 240~295 ms로 채널 공통으로 안정적입니다. USB만 사후 검사 구조상 더 길지만 업무 입력 지연과는 성격이 다르며, 미탐지 파일에는 추가 지연이 없습니다.

→ 사용자 업무 흐름을 크게 저해하지 않으면서 실시간 민감정보 반출 탐지·차단이 가능함을 확인했습니다.

4.4 AI 모델 검증 결과


AI 모델은 threshold 재검증, 홀드아웃 평가, 강건성 검증, 응답 지연시간 네 가지 관점에서 검증하였습니다.

1	Threshold 검증	ROC 분석(AUC 0.9949)으로 0.41/0.20 threshold 도출
2	홀드아웃 평가	학습 미사용 60건, Recall 100%·오탐 0%
3	강건성 검증	변형 표현 37건 중 confidence 하락 사례 0건
4	AI 응답 지연	Colab GPU 233건 실측, 평균 17~30ms

05

결론 및 향후 과제

- 결론
- 연구 성과
- 향후 확장 방향




5.1 결론

본 연구는 정규식과 **KoELECTRA** 문맥 분석을 결합한 **Windows Host DLP (Sentry)**를 설계 및 구현하였습니다.

Host Agent가 클립보드·웹메일·클라우드 드라이브·USB 채널을 **공통 파이프라인**으로 처리하고, AI 서버가 allow / review / block 판정을 수행하며, Web Dashboard가 로그·통계·위험 알리를 제공합니다.

실사용 구간(100 KB~1 MB)에서 USB를 제외한 채널은 **1초 이내** 탐지·차단이 가능하였고, AI 추론은 **240~295 ms**로 안정적이었습니다. 동일 event_id로 단말 조치와 중앙 관제를 연결함으로써, 하이브리드 탐지와 중앙 모니터링이 가능한 기반을 검증하였습니다.

5.2 연구 성과



다중 채널 탐지

클립보드 · 웹메일 · 클라우드
드라이브 · USB 공통
파이프라인 구현

AI 문맥 분석

정규식 후보를 KoELECTRA로
재판정하는 3단계 판정 API

중앙 관제 화면

로그 수집 · 검색 · 통계 · 상세
근거 · 위험 알림 구현

구성 요소 연동

동일 event_id로 AI · Host ·
Web 사건을 추적 · 맥등 저장

5.3 향후 확장 방향

계약 정합화



Clipboard · Cloud Drive 채널 매핑, model_version 전달, allow 기록 범위와 실제 조치 결과 상태를 일치시킨다.

모델 품질 확장



60건 규모의 독립 홀드아웃 평가를 완료하였으며, 향후 부서 · 문서 유형 단위 분할과 실제 기업 문서 기반 대규모 독립 평가를 진행한다.

실장비 통합 및 성능 측정



실제 Windows 장비의 대상 채널과 다른 PC의 대시보드를 연결하고 CPU · RAM 사용률, P95와 종단 지연 재현성을 측정한다.

운영 보안과 확장성



Host-AI 인증과 민감 로그 축소, 개발용 비밀정보 교체, HTTPS 적용, DB 접근통제 · 백업 · 보존과 대용량 로그 구조를 확장한다.

cse.pusan.ac.kr



Thank You

감사합니다